

基于深度学习的在线课程异常行为检测平台

学号：2112630527

姓名：胥琮璟

摘要：随着在线教育平台和大规模开放在线课程的快速发展，学习过程产生了海量点击流、视频播放、作业测验、讨论互动和终端访问日志。学习行为数据一方面为教学诊断与个性化干预提供了基础，另一方面也暴露出刷课、代学、异常挂机、异常答题和退课风险等问题。传统规则方法依赖人工经验，难以适应课程差异和行为时序变化。本文以“基于深度学习的在线课程异常行为检测平台”为研究对象，在学习分析与教育数据挖掘理论基础上，结合知识追踪、时序异常检测和Transformer注意力机制，设计了一个面向在线课程场景的数据采集、特征建模、异常识别、告警干预和可视化管理平台。平台采用“行为序列建模+重构造误差检测+规则约束校验”的混合方案：首先对学习日志进行清洗、会话切分和多粒度特征构建；其次利用深度序列模型捕捉学习状态演化，利用自编码器或变分自编码器学习正常行为分布，并通过融合评分输出异常等级；最后将检测结果反馈给教师端、教务端和学生端，支持证据追溯和教学干预。系统测试表明，该方案能够在保证可解释性的同时提升复杂异常行为的识别能力，对规范在线学习秩序和提升教学质量具有一定应用价值。

关键词：在线课程；异常行为检测；深度学习；学习分析；教育数据挖掘；Transformer

1 引言

在线课程改变了传统课堂的组织方式，使学习者能够在不同时间、地点和终端上完成课程学习。课程平台记录的学习轨迹包括登录、观看视频、拖动进度条、暂停、倍速播放、提交作业、参与讨论、测验答题等细粒度事件。这些数据推动了学习分析与教育数据挖掘的发展。Siemens和Baker指出，学习分析与教育数据挖掘都关注从教育大数据中发现可解释、可行动的规律，但二者在研究取向和应用目标上有所侧重[1]。Baker和Siemens进一步总结了教育数据挖掘在学习过程诊断、学习资源推荐和教学决策支持中的价值[2]。因此，利用行为数据识别异常学习状态，已经成为在线教育质量保障的重要方向。

在线课程异常行为具有隐蔽性、时序性和多样性。一类异常与学习真实性相关，例如短时间内完成大量视频学习、频繁拖动至视频末尾、长时间无交互却保持在线、同一账号短时跨地区登录等；另一类异常与学习风险相关，例如连续缺课、测验正确率突降、学习间隔异常增大、讨论参与突然停止等。与传统考试作弊识别不同，在线课程异常检测需要持续处理海量日志，并在课程进行过程中给出及时提醒。MOOCube数据集包含课程、概念和大规模学生行为，为在线教育人工智能研究提供了典型数据基础[3]，也说明真实学习行为具有多源异构和长序列特征。

深度学习适合处理在线课程行为序列。Piech等提出的Deep Knowledge Tracing使用循环神经网络刻画学生知识状态随时间变化的过程[4]，说明深度序列模型能够从交互历史中学习隐含学习状态。Whitehill等在MOOC退课预测研究中发现，深层前馈网络可以提高退课预测效果

[5]；Hancox和Relton则将时间图结构与卷积神经网络结合，用于在线课程退课预测[6]。这些研究为异常行为检测提供了方法启发：异常并不只是单点规则违背，还可能表现为学习节奏、知识掌握和行为上下文之间的不一致。

本文围绕平台建设展开研究，目标是在完整业务流程中实现异常行为的自动检测与可解释干预。全文结构如下：第二部分介绍相关技术；第三部分进行系统需求与可行性分析；第四部分给出系统总体设计；第五部分说明关键模块实现；第六部分设计测试方案并分析结果；最后总结研究工作并展望后续改进方向。

2 相关技术介绍

2.1 学习分析与教育数据挖掘

学习分析强调对学习者及其学习环境数据的测量、收集、分析和报告，目的在于理解和优化学习过程[1]。教育数据挖掘更关注算法模型和数据模式发现，常用于学生表现预测、学习路径推荐、知识掌握诊断和异常行为识别[2]。在线课程平台中的行为日志具有连续性和细粒度特征，既可以用于统计分析，也可以输入机器学习模型形成预测与预警能力。

学习行为数据通常包括三类：第一类是学习过程数据，如视频播放、暂停、回看、倍速、章节访问、页面停留；第二类是学习结果数据，如作业提交、测验得分、答题时长和正确率；第三类是环境数据，如登录IP、设备类型、浏览器、地理位置和网络状态。异常检测平台需要把这些数据统一映射为可计算的特征，并与课程结构、知识点和教学日历相结合。

2.2 深度学习序列建模

在线课程行为天然具有时间顺序。例如，一个学生先观看知识点视频，再完成对应测验；若出现未观看核心内容却在极短时间内高分通过测验，可能提示代学或答案泄露风险。循环神经网络、长短期记忆网络和门控循环单元能够处理时间依赖关系。Deep Knowledge Tracing证明，RNN可以从学生练习记录中学习潜在知识状态并预测后续表现[4]。

Transformer利用自注意力机制直接建模序列中任意两个位置之间的依赖关系[12]，适合处理长学习行为序列。相较RNN，Transformer并行度更高，并能通过注意力权重展示关键行为片段。对于在线课程异常检测，Transformer可用于识别“行为上下文不匹配”，如测验提交与前序学习内容之间的关联过弱、学习节奏突然偏离同群体模式等。

2.3 时序异常检测方法

异常检测可分为监督、半监督和无监督方法。在线课程中的异常标签往往稀缺，人工标注成本高，因此平台需要更多依赖半监督或无监督学习。Malhotra等提出LSTM编码器—解码器，通过重构正常多传感器时序并利用重构误差判断异常[8]。Xu等提出Donut，使用变分自编码器检测Web应用季节性KPI异常[9]。这些方法可以迁移到在线课程行为时间序列中，用于学习正常学习节奏分布。

复杂场景下，单一重构误差可能不足以解释异常。Su等提出OmniAnomaly，利用随机循环神经网络和重构概率实现多变量时序异常检测，并提供变量级解释[10]。Xu等提出Anomaly Transformer，利用关联差异刻画异常点与整体序列之间的注意力分布差别[11]。在线课程平台可借鉴这些思想，既检测行为序列是否偏离正常分布，也解释哪些事件、时间段或指标导致异常评分升高。

3 系统分析

3.1 需求分析

平台面向学生、教师、教务管理员和系统管理员四类用户。学生端需要展示个人学习进度、学习建议和异常提醒；教师端需要查看班级学习画像、异常名单、证据链和干预记录；教务端需要进行课程质量监控、诚信风险统计和跨课程对比；系统管理员负责用户权限、模型配置、数据接口和系统运行维护。

功能需求包括：（1）数据采集：对接在线课程平台的学习日志、测验系统、账号系统和课程资源库；（2）数据治理：完成日志清洗、缺失处理、去重、会话划分、匿名化和特征生成；（3）异常检测：识别刷课、挂机、代学疑似、异常答题、退课风险和账号安全异常；（4）告警管理：按照异常等级推送给教师或教务人员，并支持人工复核；（5）可视化分析：展示个人、班级、课程和时间维度的行为趋势；（6）模型管理：支持模型训练、评估、版本发布和阈值调整。

3.2 异常行为定义

本文将在线课程异常行为定义为：在给定课程结构、学习任务、学习者历史行为和群体行为背景下，显著偏离正常学习规律，且可能影响学习真实性、学习效果或平台安全的行为模式。该定义强调上下文关系，同一个行为在不同课程阶段可能具有不同含义。例如，期末复习期间的高频回看可能是正常行为，而新课发布后立即完成全章节视频并满分测验则可能异常。

异常类别	典型表现	关键特征	检测策略
刷课/快进	短时间完成大量视频、频繁拖拽进度条、拖动次数、倍速、章节完成间隔	观看时长、拖拽次数、倍速、章节完成间隔	规则约束+序列模型
挂机学习	长时间在线但无暂停、答题、讨论等交互行为	空闲时长、事件密度、鼠标键盘间隔	会话特征+阈值评分
异常答题	答题极快且正确率异常、与学习进度不匹配	答题时长、正确率、知识点覆盖、前序学习路径	知识追踪+异常分数
退课风险	连续缺课、学习间隔增大、讨论参与度低	缺课次数、最近访问间隔、任务完成率	深度预测模型
账号异常	短时间跨设备、跨地区登录	IP变化、设备指纹、登录时间差	安全规则+聚类检测

表1 在线课程异常行为类别与特征设计

3.3 可行性分析

技术可行性方面，在线课程平台已经能够记录结构化日志，深度学习框架可以支撑序列建模和异常检测。经济可行性方面，系统主要复用现有课程平台数据，部署成本集中在数据存储、模型训练和可视化服务，符合高校在线教学质量监控需求。操作可行性方面，平台以可视化告警和证据链呈现为主，教师无需理解复杂模型即可进行复核和干预。安全可行性方面，平台应采用数据脱敏、权限控制和审计日志，避免把异常检测结果简单等同于违纪结论。

4 系统设计

4.1 总体架构设计

平台采用分层架构，包括数据源层、数据处理层、模型服务层、业务应用层和安全运维层。数据源层对接学习管理系统、视频平台、测验系统、论坛系统和账号认证系统；数据处理层完成日志标准化、行为编码、特征抽取和样本构建；模型服务层提供序列预测、重构检测、规则校验和融合评分；业务应用层提供教师看板、学生反馈、教务报表和告警处置；安全运维层负责身份认证、访问控制、模型监控和日志审计。




图1 基于深度学习的在线课程异常行为检测平台总体架构

4.2 数据库设计

数据库采用关系型数据库和日志存储相结合的方式。关系型数据库保存用户、课程、章节、知识点、作业、告警和复核记录；日志存储系统保存原始行为事件和模型中间特征。核心表包括用户表、课程表、行为日志表、会话表、特征表、异常结果表和干预记录表。行为日志表字段包括event_id、user_id、course_id、event_type、resource_id、event_time、device_id、ip_hash、duration和extra_json。异常结果表字段包括result_id、user_id、course_id、anomaly_type、score、level、evidence、model_version、created_at和review_status。

4.3 模型流程设计

模型流程包括四步。第一步为行为编码，将不同事件类型映射为离散符号，并把时间间隔、资源类型、知识点、设备信息等转化为连续特征。第二步为正常模式学习，利用历史正常样本训练序列模型和自编码器。第三步为异常评分，序列模型输出行为概率或退课风险，自编码器输出重构误差，规则模块输出硬约束分值。第四步为分数融合，按照业务权重和模型置信度形成综合异常分数，并划分为低、中、高三个等级。

融合评分可表示为： $S = \alpha S_{seq} + \beta S_{rec} + \gamma S_{rule} + \delta S_{risk}$ 。其中 S_{seq} 表示行为序列偏离分数， S_{rec} 表示重构误差分数， S_{rule} 表示规则命中分数， S_{risk} 表示学习风险分数， α 、 β 、 γ 、 δ 为可调权重。该设计兼顾深度模型的泛化能力和业务规则的可解释性，避免仅凭黑盒模型作出判断。

4.4 安全与伦理设计

异常检测涉及学生隐私与教育公平。平台只输出“疑似异常”而非直接判定违规，重要告警必须经过教师或教务人员人工复核。系统应对个人身份、IP和设备信息进行脱敏存储，并按照最小权限原则开放数据。模型训练应关注群体差异，防止把网络条件较差、学习时间不规律等非主观因素误判为异常。

5 系统实现

5.1 数据采集与预处理实现

数据采集模块通过消息队列或定时任务接入学习平台日志。每条原始事件统一转换为标准事件格式，包括用户标识、课程标识、事件类型、资源标识、时间戳、持续时长和扩展字段。预处理阶段首先去除重复事件和明显错误时间戳，然后按照30分钟无操作切分学习会话，最后生成日、周、章节和课程四个粒度的特征。为减少噪声，系统对极端时长采用分位数截断，对缺失设备信息设置未知类别。

5.2 特征工程实现

平台构建行为频次特征、时间节奏特征、学习路径特征、测验表现特征和安全环境特征。行为频次特征包括视频播放次数、暂停次数、拖动次数、作业提交次数等；时间节奏特征包括学习间隔、会话长度、任务完成速度；学习路径特征描述资源访问顺序与课程知识结构之间的匹配程度；测验表现特征包括答题时长、正确率、重做次数和知识点覆盖；安全环境特征包括设备数量、IP变化频率和异地登录间隔。

5.3 深度模型实现

序列分支使用GRU或Transformer编码学习行为序列。输入为事件嵌入、时间间隔嵌入和资源嵌入的拼接向量，输出为下一事件预测概率、学习风险概率和隐藏状态表示。对于长序列课程，Transformer分支能够捕捉跨章节依赖关系[12]；对于数据量较小的课程，GRU分支更容易训练并具有较低部署成本。

重构分支使用LSTM编码器—解码器或变分自编码器。正常学习行为经过编码后应能被较好重构，异常行为则会产生较高重构误差。该思路与多传感器异常检测中的EncDec-AD一致[8]，也与Donut利用VAE检测季节性KPI异常的思想相近[9]。对于多维行为数据，系统参考OmniAnomaly的变量级解释方法[10]，输出导致异常的主要指标，例如“视频完成速度”“答题时长”“IP变化频率”等。

关联分析分支借鉴Anomaly Transformer的关联差异思想[11]。正常学习行为通常与课程知识结构、前后学习任务和群体节奏存在稳定关联，而异常行为往往只与局部事件相关，难以形成合理的长程依赖。系统通过注意力权重可视化展示异常片段，帮助教师理解告警原因。

5.4 业务模块实现

教师端看板包括课程概览、异常学生列表、异常类型分布、时间趋势图和证据详情页。证据详情页展示触发告警的行为片段，例如某学生在5分钟内完成3个章节视频，且随后以极短时间完成测验。教务端报表按课程、班级和教师维度统计异常率，辅助评估课程运行质量。学生端只展示改进建议和学习提醒，不展示复杂模型分数，避免造成不必要压力。

6 系统测试

6.1 测试环境与测试数据

系统测试采用离线历史数据回放与模拟异常注入相结合的方法。离线数据包括若干门在线课程的学习日志、视频访问记录和测验记录；模拟异常包括快进刷课、挂机、异常答题和跨设备登录。评价指标包括准确率、精确率、召回率、F1值、AUC、平均告警延迟和人工复核通过率。退课风险类测试参考MOOC退课预测研究的周粒度预测设置[5][6][7]。

测试项目	输入场景	预期结果	评价重点
数据接入测试	导入登录、视频、测验和讨论日志	日志正确入库并完成标准化	完整性、去重率
刷课检测测试	短时高倍速完成多章节视频	生成中高等级刷课告警	召回率、证据链
异常答题测试	未学习知识点却极短时间高分通过	生成异常答题告警	精确率、可解释性
退课风险测试	连续多周活跃度下降	输出退课风险等级	AUC、告警提前量
权限测试	学生访问教师端告警列表	拒绝访问并记录审计日志	安全性

表2 主要测试用例与预期结果

6.2 测试结果分析

测试结果表明，单纯规则方法在刷课等显性异常上表现较好，但对退课风险和异常答题等上下文异常识别不足；单纯深度模型能够发现复杂模式，但解释性较弱。融合方案综合两者优势，在多数异常类型上取得更稳定表现。对于刷课和挂机，规则模块提供明确证据；对于退课风险，深度序列模型能够利用连续学习间隔和任务完成趋势提前预警；对于异常答题，知识追踪思想有助于判断测验表现是否与前序学习状态一致[4]。

系统性能方面，数据预处理采用批流结合方式，日常日志可以准实时进入特征库；模型推理服务通过批量请求降低延迟，能够满足教师端分钟级告警需求。误报主要来自网络异常、学生集中补课和共享设备等情况，因此平台提供人工复核、申诉说明和阈值调整机制。总体来看，系统能够为在线课程质量监控提供有效技术支撑。

7 总结与展望

本文围绕“基于深度学习的在线课程异常行为检测平台”完成了需求分析、总体设计、关键实现和测试方案。平台以学习分析和教育数据挖掘为理论基础，结合知识追踪、序列建模、重构式异常检测和注意力机制，形成了从日志采集到异常告警再到人工复核的闭环流程。与传统规则系统相比，本文方案能够处理多源异构和长时序学习行为；与单一深度模型相比，融合规则和证据链设计增强了可解释性和可落地性。

未来研究可从四个方面改进：第一，引入联邦学习和隐私计算，在不集中暴露学生原始数据的情况下训练跨校模型；第二，构建更细粒度的知识图谱，将异常行为与课程知识结构深度结合；第三，探索因果推断方法，区分主观异常、客观困难和平台故障；第四，开展真实教学场景中的长期实验，评估告警干预对学习效果、课程完成率和学生体验的影响。在线课程异常检测不应只服务于监管，更应服务于学习支持与教学改进。

参考文献

- [1] Siemens G, Baker R S J d. Learning analytics and educational data mining: Towards communication and collaboration[C]//Proceedings of the 2nd International Conference on Learning Analytics and Knowledge. 2012: 252-254.
- [2] Baker R S J d, Siemens G. Educational data mining and learning analytics[M]//The Cambridge Handbook of the Learning Sciences. Cambridge University Press, 2014: 253-274.
- [3] Yu J, Luo G, Xiao T, et al. MOOCCube: A large-scale data repository for NLP applications in MOOCs[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 3135-3142.
- [4] Piech C, Bassen J, Huang J, et al. Deep knowledge tracing[C]//Advances in Neural Information Processing Systems. 2015, 28.
- [5] Whitehill J, Mohan K, Seaton D, Rosen Y, Tingley D. Delving deeper into MOOC student dropout prediction[J/OL]. arXiv:1702.06404, 2017.
- [6] Hancox Z, Relton S D. Temporal graph-based CNNs (TG-CNNs) for online course dropout prediction[C]//Foundations of Intelligent Systems. Cham: Springer, 2022: 357-367.
- [7] Gao W, Liu Q, Huang Z, et al. Deep attentive study session dropout prediction in mobile learning environment[J/OL]. arXiv:2002.11624, 2020.
- [8] Malhotra P, Ramakrishnan A, Anand G, et al. LSTM-based encoder-decoder for multi-sensor anomaly detection[J/OL]. arXiv:1607.00148, 2016.
- [9] Xu H, Chen W, Zhao N, et al. Unsupervised anomaly detection via variational auto-encoder for seasonal KPIs in web applications[C]//Proceedings of the Web Conference 2018. 2018: 187-196.

- [10] Su Y, Zhao Y, Niu C, Liu R, Sun W, Pei D. Robust anomaly detection for multivariate time series through stochastic recurrent neural network[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 2828-2837.
- [11] Xu J, Wu H, Wang J, Long M. Anomaly Transformer: Time series anomaly detection with association discrepancy[C]//International Conference on Learning Representations. 2022.
- [12] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017, 30.